

Sistema de Descoberta de Empresas (CNPJs)

Especificação técnica do sistema de pipeline e API de consumo.

1. Pipeline Offline (24/7)

Uma IA roda continuamente processando dados públicos de CNPJs. O pipeline é dividido em etapas sequenciais obrigatórias.

Etapla 1 — Coleta da Base Pública O sistema lê a base pública (SERPRO+) filtrando apenas empresas abertas nos últimos 1 a 2 anos. A janela de 2 anos existe para períodos de baixa abertura de empresas (ex: janeiro), evitando que o produto pareça vazio.

Etapla 2 — Enriquecimento Obrigatório Antes de qualquer processamento por IA, cada CNPJ passa por uma API gratuita de consulta que retorna:

- Nome fantasia
- Razão social
- Atividade principal (CNAE)
- Situação cadastral
- Endereço (quando disponível — tratado estruturalmente em texto, focando em campos como Município, Bairro e CEP, sem necessidade de coordenadas geográficas na V1)

Essa etapa é obrigatória — CNPJs sem dados suficientes não avançam no pipeline. O sistema precisa de retry com fila robusta, pois a disponibilidade do SERPRO é instável.

Etapla 3 — Processamento por IA Somente após o enriquecimento, a IA entra em cena e:

- Interpreta o que a empresa faz
- Normaliza a descrição do negócio
- Cria uma representação semântica (embedding)
- Classifica internamente o tipo de empresa

Banco Processado O sistema salva tudo já enriquecido:

- CNPJ + dados da API pública
- Embedding gerado
- Categoria interpretada pela IA
- Data de entrada no sistema

Um ciclo de re-processamento periódico garante que mudanças de CNAE ou situação cadastral não tornem os embeddings obsoletos.

2. API de Consumo (sem IA) e Ferramentas de Inteligência

A API não roda IA. Ela apenas busca no banco já processado, compara o interesse do usuário com os embeddings existentes e aplica as regras de exposição. Nenhuma IA roda em tempo real.

Motor de Busca e Inteligência de Mercado Aproveitando o banco processado e os embeddings gerados na Etapa 3, o sistema oferece as seguintes dinâmicas de descoberta utilizando agrupamentos de banco de dados (GROUP BY , COUNT , LIKE):

- **Busca Semântica Avançada:** Em vez de filtrar de forma genérica (ex: "Restaurantes"), o usuário digita uma frase complexa como: *"Empresas que provavelmente precisam de embalagens sustentáveis para delivery"*. O sistema transforma essa frase de interesse em um embedding e a API de consumo compara com a base.
- **Prospecção Lookalike:** O usuário insere o CNPJ de um cliente atual que ele adora. A API calcula a distância vetorial e encontra empresas que pensam e atuam de forma parecida.
- **Alertas por Nicho + Região:** O usuário cadastra filtros fixos baseados em texto (ex: *"Clínicas de Estética"* no bairro *"Pituba"* ou município *"Salvador"*) e, assim que o sistema finaliza o processamento de novos CNPJs, envia uma notificação ou e-mail informando: *"X empresas de estética abriram na Pituba neste período"*.
- **Termômetro de Empreendedorismo:** Informa ativamente quais cidades ou bairros possuem o ciclo de renovação empresarial mais acelerado. O backend agrupa as novas entradas pela string de "Bairro" ou "Município" em janelas de tempo, sem uso de queries espaciais.
- **Dashboard de Crescimento de Nicho:** Exibe gráficos para o assinante mostrando se o nicho de interesse dele (ex: Estética) está crescendo ou retraindo em uma região específica mês a mês.
- **Mapas de Calor Tabulares (Grid Heatmaps / Treemaps):** Mostra visualmente em quais bairros ou cidades um determinado nicho está em expansão. Em vez de mapas cartográficos com coordenadas, a interface utiliza matrizes (bairros nas linhas, meses nas colunas) ou gráficos de blocos proporcionais, entregando o valor visual de densidade sem depender de latitude e longitude.

Regras de Exposição (Nota: As regras abaixo aplicam-se a todas as entregas do sistema, incluindo resultados revelados a partir de Alertas, Lookalike e Busca Semântica)

- **Cooldown global:** cada CNPJ aparece no máximo 2 vezes por semana para qualquer usuário, depois entra em pausa automática.
- **Paginação fixa:** páginas não mudam após geradas — o usuário pode voltar à página 1 e ver os mesmos resultados.
- **Histórico pessoal:** tudo que o usuário viu fica salvo na seção "Clientes que você já descobriu" (histórico organiza, não bloqueia).
- **Bloqueio manual:** se o usuário clicar "não quero ver mais", aquele CNPJ nunca mais aparece para ele.

Modelo de Assinatura e Limite diário de descobertas O acesso ao sistema é exclusivamente por assinatura mensal. Não há compra avulsa de créditos.

- Cada plano de assinatura possui um limite de CNPJs descobertos por dia.
- O limite é proporcional ao plano contratado (valores a definir conforme precificação).
- A revelação de CNPJs (seja pela busca manual ou acessando a plataforma para revelar a lista de um Alerta recebido) desconta desse montante. A exibição de dados agregados nos dashboards não consome limite.
- Ao atingir o limite diário, o usuário recebe a mensagem: "Você chegou ao fim das suas descobertas de hoje. Volte amanhã!"
- O contador reinicia automaticamente a cada dia.

O limite diário cria cadência de uso, reforça o valor do produto e evita que o usuário esgote a base disponível de uma só vez.

3. Anti-Scraping — Criptografia no Payload

A principal superfície de ataque não é a tela, mas a aba de rede do navegador: um bot pode escutar a API e puxar o JSON diretamente. Para mitigar isso:

- A API nunca retorna JSON em texto claro.
- Ela retorna uma string encriptada (AES).
- O frontend recebe essa string, usa uma chave interna para descriptografar e só então renderiza os dados.
- Os dados — incluindo CNPJ, contato e demais informações — aparecem diretamente na tela, sem necessidade de clique adicional.
- Um bot escutando a aba de rede só recebe lixo ilegível.

Nota: nenhuma solução é 100% inviolável, mas a criptografia do payload eleva significativamente o custo de um ataque automatizado, tornando o scraping pouco prático.

Resumo do Fluxo Completo

1. **Coleta** — base pública SERPRO+ (últimos 1–2 anos).
2. **Enriquecimento obrigatório** — API gratuita de CNPJ complementa os dados oficiais em formato de texto.
3. **IA offline** — interpreta a empresa, gera embedding e salva no banco.
4. **Usuário faz busca por interesse** — (via Busca Semântica, Lookalike, Dashboards ou Alertas configurados) através de sua assinatura mensal.
5. **API de consumo** — busca empresas prontas utilizando semântica e campos de texto, e aplica cooldown global e histórico do usuário.
6. **Limite diário atingido** — consumo encerra com a mensagem "Volte amanhã" e o contador reinicia no dia seguinte.
7. **Retorno** — lista paginada entregue com payload encriptado (AES).